

PORTFOLIO

AI 기반 RAG 챗봇 자동 품질 평가 시스템

Two-Stage Evaluation 기반 LLM Judge Agent 설계 및 구현

RAG · LLM-as-a-Judge · QA 자동화 · 품질 리포트 자동 생성

분야	AI 품질 평가 / QA 자동화
핵심 역할	Judge Agent 설계 · 평가 파이프라인 구현
주요 기술	Python · LangChain · OpenAI GPT-4.1-mini · ChromaDB
산출물	자동 생성 Markdown 품질 평가 리포트

목 차

1. 프로젝트 개요.....	3
2. 시스템 아키텍처.....	4
3. 기술 스택.....	5
4. 평가 프로세스.....	6
5. 평가 기준 — Two-Stage Evaluation.....	7
6. 테스트 결과.....	8
7. 문제 해결 사례.....	9
8. 프로젝트 성과.....	10
9. 한계 및 향후 개선 계획.....	11

1. 프로젝트 개요

구분	내용
프로젝트명	AI 기반 RAG 챗봇 자동 품질 평가 시스템
한 줄 요약	RAG 챗봇의 답변 품질을 LLM Judge Agent 가 자동으로 평가·진단하고 리포트를 생성하는 시스템
핵심 목표	사람의 수작업 평가를 대체하는 일관된 자동 품질 평가 체계 구축
평가 방식	Two-Stage Evaluation (루브릭 평가 + 감점 평가 분리)
핵심 산출물	항목별 점수 · 진단 · 개선 코멘트가 담긴 Markdown 품질 리포트 자동 생성

■ 프로젝트 배경 및 목적

RAG(Retrieval-Augmented Generation) 챗봇은 검색된 문서를 근거로 답변을 생성하기 때문에, 답변의 품질을 평가하려면 검색 정확도와 생성 품질을 함께 살펴야 한다. 그러나 사람이 직접 답변을 채점하는 방식은 평가자마다 기준이 달라 점수가 흔들리고, 테스트 건수가 늘어날수록 많은 시간이 소요된다.

본 프로젝트는 이러한 한계를 해결하기 위해 LLM 을 평가자(Judge)로 활용하는 자동 품질 평가 시스템을 구축했다. 단순히 점수만 매기는 데 그치지 않고, 루브릭 기반 평가 · 감점 규칙 적용 · 자동 진단 · Markdown 리포트 생성까지 전 과정을 자동화하여, 반복적인 QA 업무를 표준화된 파이프라인으로 전환하는 것을 목표로 했다.

2. 시스템 아키텍처

사용자 질문이 입력되면 RAG 서비스가 벡터 DB에서 유사 문서를 검색하고, LLM이 검색된 문서만을 근거로 답변을 생성한다. 생성된 답변은 Judge Agent로 전달되어 두 단계 평가를 거친 뒤, 최종적으로 Markdown 형식의 품질 리포트로 정리된다.

① **User Question** 사용자 질문 입력



② **RAG Service** 검색·생성 오케스트레이션



③ **Vector DB (Chroma)** 유사 문서 검색



④ **GPT-4.1-mini** 근거 기반 답변 생성



⑤ **Judge Agent** Two-Stage 품질 평가



⑥ **Markdown Report** 품질 리포트 자동 생성

3. 기술 스택

구분	기술	역할
Language	Python	전체 파이프라인 구현
LLM	OpenAI GPT-4.1-mini	답변 생성 및 Judge 평가
Embedding	text-embedding-3-small	문서·질문 임베딩
Vector DB	ChromaDB	유사 문서 저장·검색
Framework	LangChain	RAG 파이프라인 구성
문서 처리	PyPDFLoader · TextLoader	PDF·텍스트 문서 로드
환경 변수	python-dotenv	API 키 등 환경 설정 관리
평가 방식	Two-Stage Evaluation (TSE)	루브릭 + 감점 분리 평가

Two-Stage Evaluation 채택 이유

단일 점수 산정 방식은 평가 근거가 불투명하고 점수가 부풀려지는 인플레이션 문제가 발생하기 쉽다. 이를 막기 위해 ‘무엇을 잘했는가(루브릭)’와 ‘무엇을 어겼는가(감점)’를 별도 단계로 분리하여, 평가 일관성과 설명 가능성을 동시에 확보했다.

4. 평가 프로세스

질문 입력부터 리포트 생성까지 다섯 단계로 자동 수행된다.

단계	작업	설명
Step 1	RAG 검색	사용자 질문과 가장 유사한 문서를 벡터 DB 에서 검색한다.
Step 2	답변 생성	검색된 문서만을 근거로 챗봇 답변을 생성한다.
Step 3	Judge Agent 평가	GPT-4.1-mini 가 이해도·정확성·관련성·표현성 네 항목을 루브릭에 따라 평가한다.
Step 4	감점 규칙 적용	출처 미제시, 정의만 제공, 문서 근거 미사용 등 규칙 위반 항목에 대해 자동 감점한다.
Step 5	리포트 생성	항목별 점수와 진단·개선 코멘트를 담은 Markdown 품질 리포트를 자동 생성한다.

5. 평가 기준 — Two-Stage Evaluation

1 단계 · 루브릭 평가

답변의 질을 네 가지 항목으로 나누어 정성적으로 채점한다.

항목	평가 내용
이해도	질문의 의도를 정확히 파악했는가
정확성	검색된 문서 근거에 기반한 답변인가
관련성	질문과 답변이 적합하게 연결되는가
표현성	가독성과 표현이 자연스러운가

2 단계 · 감점 평가

루브릭 점수와 별개로, 명시적 규칙을 위반한 경우 정량적으로 감점한다.

감점 규칙	감점
출처 미기재	-1
정의만 제공	-1
근거 문서 미사용	-1
문서가 존재함에도 “모르겠습니다”로 응답	-2

6. 테스트 결과

항목	결과
총 테스트 건수	5 건
평균 점수	4.30 / 5.00
평가 방식	Two-Stage Evaluation
리포트 생성	자동

결과 해석

5 건의 테스트에서 평균 4.30 점을 기록했으며, 모든 평가 결과는 사람의 개입 없이 자동으로 리포트화되었다. 점수와 함께 감점 사유·진단 코멘트가 제공되어 '왜 그 점수인지'를 추적할 수 있다.

■ 주요 개선 사례 — 점수 인플레이션 보정

초기 루브릭에서는 답변에 실질 정보가 없어도 이해도·관련성이 만점으로 매겨지는 점수 인플레이션이 발생했다. 루브릭 기준을 보완하여, 문서에서 정보를 찾지 못한 답변은 관련성 점수가 제한되도록 수정했다.

Before — 점수 인플레이션	After — 기준 보정
질문: 교육과정은 총 몇 시간인가요?	질문: 교육과정은 총 몇 시간인가요?
답변: 제공된 문서에서는 확인할 수 없습니다.	답변: 제공된 문서에서는 확인할 수 없습니다.
이해도 5 · 관련성 5	이해도 4 · 관련성 3
실질 정보가 없어도 만점 → 신뢰도 저하	정보 부재 시 관련성 점수 제한 → 변별력 확보

7. 문제 해결 사례

문제 1

- **문제** 단순 점수만 제공되어 낮은 점수의 원인을 알 수 없음
- **해결** 루브릭 점수와 감점 사유를 함께 제공하는 리포트로 평가 근거를 명확히 함

문제 2

- **문제** 평가자마다 기준이 달라 점수가 주관적으로 흔들림
- **해결** GPT Judge 프롬프트를 표준화하여 평가 일관성을 확보함

문제 3

- **문제** 품질 보고서를 수작업으로 작성해 많은 시간이 소요됨
- **해결** Markdown 리포트를 자동 생성하여 QA 업무를 자동화함

8. 프로젝트 성과

- ✓ LLM(GPT-4.1-mini) 기반 Judge Agent 구현
- ✓ Two-Stage Evaluation(루브릭 + 감점 분리) 평가 체계 적용
- ✓ 사람 개입 없는 자동 품질 평가 시스템 구축
- ✓ 항목별 점수·진단을 담은 Markdown 리포트 자동 생성
- ✓ RAG 응답 품질의 자동 진단 및 개선 포인트 도출
- ✓ 반복적인 QA 업무의 표준화 및 자동화

■ 배운 점

- RAG 시스템은 검색 성능과 답변 품질을 함께 평가해야 한다.
- 루브릭 평가와 감점 규칙을 분리(TSE)하면 평가 일관성을 높일 수 있다.
- LLM을 Judge Agent로 활용하면 반복적인 QA 업무를 자동화할 수 있다.
- 자동화된 Markdown 리포트는 테스트 결과를 체계적으로 관리·공유하는 데 효과적이다.

9. 한계 및 향후 개선 계획

■ 현재 한계

- 평가 기준이 LLM 프롬프트에 의존하여 프롬프트 설계 품질에 민감하다.
- 문서에 존재하지 않는 질문은 사용자 만족도 관점의 평가가 어렵다.
- 한글 파일명 기반 메타데이터 처리의 안정성 개선이 필요하다.

■ 향후 개선 방향

- BLEU · ROUGE · BERTScore 등 정량 지표와 결합하여 평가 신뢰도 강화
- 다중 Judge(LLM Ensemble) 적용으로 단일 모델 편향 완화
- Streamlit 대시보드 연동으로 결과 가시성 향상
- 평가 결과를 프롬프트 엔지니어링·파인튜닝에 반영하는 자동 피드백 루프 구축

프로젝트 요약

본 프로젝트는 RAG 챗봇 품질 평가라는 반복적이고 주관적인 QA 업무를, Two-Stage Evaluation 기반의 LLM Judge Agent 로 표준화·자동화한 사례다. 평가의 목적·설계·구현·결과·개선 방향을 일관되게 연결하여, 문제를 어떻게 정의하고 해결했는지를 실무 관점에서 보여준다.