


2주차 과제 보고서

생성형 AI 프롬프팅 기반 height.csv 탐색 및 분석 코드 검증

과정명	2026 생성형 AI를 활용한 탐색적 데이터 분석
분석 데이터	height.csv (n=55, 변수: height)
제출일	2026년 8월 28일 (금)
제출자	유현주

0. 데이터셋 개요 및 제공된 분석 결과

height.csv는 n=55의 단일 변수(height, cm, int64) 데이터셋입니다. 아래 요약 통계표와 박스플롯이 제공되었으며, 이를 바탕으로 탐색적 질문을 도출하였습니다.



항목	값 cm	통계적 의미
평균 (Mean)	171.42	전체 데이터의 중심값
중앙값 (Median)	171.0	평균과 거의 동일 → 대칭 분포
표준편차 (Std Dev)	4.80	개인 간 편차 수준
최소/최대	162 / 181	범위(Range) = 19 cm
Q1 / Q3	168 / 175	IQR = 7 cm
왜도 (Skewness)	0.05	skew <0.5: 거의 대칭
첨도 (Kurtosis)	-0.75	정규(=0)보다 납작 → Platykurtic

▼ 제공된 박스플롯 원본

[그림 0-1] 제공된 height 분포 박스플롯 및 요약 통계표

▶ 박스의 중앙선(중앙값=171)이 박스 중간에 위치하고 위아래 수염 길이도 비슷하여 분포가 좌우 대칭에 가깝습니다. 첨도 -0.75는 정규분포(=0)보다 봉우리가 낮고 꼬리가 가벼운 평탄 분포(Platykurtic)를 의미합니다.

1. [문항 1] 탐색적 질문(Explore) 도출 (30점)

박스플롯과 요약 통계치를 분석하여 데이터 이면의 인사이트를 파악하기 위한 통계 기반 탐색적 질문 4가지를 도출하였습니다.

Q1. 이 키 분포는 통계적으로 정규분포를 따르는가?

- 왜도 0.05는 거의 0에 가깝고, 평균(171.42)과 중앙값(171.0)의 차이도 0.42 cm에 불과합니다.
- 그러나 첨도 -0.75는 정규분포(=0)보다 유의미하게 낮아 납작한 분포 형태임을 시사합니다.
- 시각적 판단만으로는 정규성을 확정할 수 없으므로 Shapiro-Wilk 검정과 Q-Q Plot으로 통계적 검증이 필요합니다.
- [핵심 통계 개념] 정규성 검정의 귀무가설은 "정규분포를 따른다"이며, $p\text{-value} > 0.05$ 이면 귀무가설을 기각하지 않습니다.

Q2. IQR 기준으로 이상치(Outlier)가 존재하는가?

- 박스플롯의 수염(Whisker)을 벗어나는 점이 있는지 확인해야 합니다.
- $IQR = 7.0$ cm이므로 Tukey Fence 기준: 하한선 = $Q1 - 1.5 \times IQR = 157.5$ cm
- 상한선 = $Q3 + 1.5 \times IQR = 185.5$ cm → 실제 데이터(162~181 cm)가 모두 기준 내에 포함됩니다.
- [핵심 통계 개념] IQR 방법 외에 Z-점수($|Z| > 3$) 기준도 이상치 탐지에 자주 사용됩니다.

Q3. 경험적 규칙(68-95-99.7 Rule)이 이 데이터에서 성립하는가?

- 표준편차 4.80 cm이면 정규분포 경험적 규칙 예측 구간: 평균 $\pm 1\sigma = 166.62 \sim 176.22$ cm (이론: 68.3%)
- 평균 $\pm 2\sigma = 161.82 \sim 181.02$ cm (이론: 95.4%) → 실제 비율이 이론값과 유사한지 확인합니다.
- 첨도 -0.75의 평탄 분포라면 $\pm 1\sigma$ 비율이 이론값(68.3%)보다 낮을 가능성이 있습니다.
- [핵심 통계 개념] 경험적 규칙(Empirical Rule)은 정규분포의 산포 특성을 직관적으로 검증하는 도구입니다.

Q4. 키 분포의 최빈 구간은 어디이며, 분포가 단봉(Unimodal)인가?

- 박스플롯만으로는 다봉성(Multimodality) 여부를 파악하기 어렵습니다.
- 히스토그램과 KDE(커널 밀도 추정) 그래프를 시각화하면 분포의 세부 형태를 확인할 수 있습니다.
- 첨도 -0.75의 납작한 분포라면 특정 구간에 집중되지 않고 넓게 퍼진 형태일 것입니다.
- [핵심 통계 개념] KDE(Kernel Density Estimation)는 히스토그램을 연속 곡선으로 나타내어 분포 형태를 시각적으로 확인하는 데 효과적입니다.

2. [문항 2] 생성형 AI 프롬프트 엔지니어링 (40점)

문항 1의 탐색적 질문(Q1~Q4)을 해결하기 위해 Claude에게 입력한 프롬프트를 작성하였습니다. 과제 가이드라인의 4가지 필수 조건을 모두 포함하도록 설계하였습니다.

▶ 프롬프트 필수 조건 체크리스트

조건	항목	적용 내용
[조건 1]	역할 부여	"너는 파이썬 데이터 분석 전문가야"로 역할을 명확히 부여
[조건 2]	데이터 구조 설명	변수명 height, int64, n=55, 기초 통계치(평균/중앙값/표준편차/왜도/첨도) 제공
[조건 3]	구체적 분석 요구	정규성 검정/이상치 탐지/경험적 규칙 검증/히스토그램+KDE 4가지 항목 지정
[조건 4]	출력 포맷 지정	한국어 주석, dpi=150, 소수점 4자리, 한글 폰트 깨짐 방지 코드 명시

▶ Claude에게 입력한 실제 프롬프트 전문

[역할 부여]

너는 파이썬 데이터 분석 전문가야.

아래 height.csv 데이터를 사용하여 탐색적 데이터 분석(EDA)을

수행하는 파이썬 코드를 작성해줘.

[데이터 정보]

- 파일명: height.csv

- 변수: height (단위: cm, 데이터 타입: int64)

- 관측치 수: 55개

- 데이터 범위: 162 ~ 181 cm

- 기초 통계: 평균 171.42 / 중앙값 171.0 / 표준편차 4.80

왜도 0.05 / 첨도 -0.75 / Q1=168 / Q3=175

[분석 요구사항 - 4가지 탐색적 질문에 대한 코드를 작성해줘]

1. [정규성 검정]

Shapiro-Wilk 검정으로 p-value와 결론을 출력하고,

Q-Q Plot을 그려서 정규성을 시각적으로 확인해줘.

2. [이상치 탐지]

IQR 방법(Tukey Fence)으로 이상치를 탐지하고,

하한선/상한선/이상치 목록을 텍스트로 출력해줘.

3. [경험적 규칙 검증]

평균 $\pm 1\sigma$, 평균 $\pm 2\sigma$ 범위 내 데이터 비율을
이론값(68.3%, 95.4%)과 비교 출력해줘.
4. [분포 형태 시각화]
히스토그램 + KDE 곡선 + 정규분포 이론 곡선을 한 그래프에
겹쳐 그리고, 평균/중앙값선과 왜도/첨도 주석을 추가해줘.
[출력 포맷 조건]
- 코드에 한국어 주석(# 주석)을 단계별로 포함해줘.
- 그래프 dpi=150, figsize는 가독성 있게 설정해줘.
- 통계값은 소수점 4자리까지 출력해줘.
- 한글 폰트 깨짐 방지 matplotlib 설정 코드를 포함해줘.
- 모든 분석을 하나의 .py 파일로 정리해줘.

► 프롬프트 설계 의도: 단순히 "EDA를 해줘"가 아니라 데이터의 정확한 통계치를 미리 제공하여 AI가 맥락에 맞는 코드를 생성하도록 유도하였습니다. 4개 질문을 번호로 구분하여 각 항목별 명확한 코드 구조가 도출되도록 설계하였으며, 출력 포맷 조건을 세부 명시하였습니다.

3. [문항 3] 파이썬 코드 실행 및 결과 검증 (30점)

생성형 AI(Claude)가 출력한 파이썬 코드를 실행하여 오류 없이 동작하는 최종 코드와 실행 결과(텍스트 출력 및 그래프)를 제출합니다.

3-1. 기술통계 및 정규성 검정 코드

```
import pandas as pd
import numpy as np
from scipy import stats

# 데이터 로드
df = pd.read_csv("height.csv")
heights = df["height"]

# 기술통계 계산
q1, q3 = heights.quantile(0.25), heights.quantile(0.75)
iqr = q3 - q1
mean = heights.mean()
std = heights.std()

print("=" * 45)
print(f"평균(Mean)      : {mean:.4f} cm")
print(f"중앙값(Median)   : {heights.median():.4f} cm")
print(f"표준편차(Std)    : {std:.4f} cm")
print(f"왜도(Skewness)   : {heights.skew():.4f}")
print(f"첨도(Kurtosis)   : {heights.kurtosis():.4f}")

# 이상치 탐지 (Tukey Fence: Q1-1.5*IQR ~ Q3+1.5*IQR)
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr
outliers = heights[(heights < lower) | (heights > upper)]
print(f"IQR 하한선      : {lower:.1f} cm")
print(f"IQR 상한선      : {upper:.1f} cm")
print(f"이상치 수       : {len(outliers)}개")

# Shapiro-Wilk 정규성 검정
stat, p = stats.shapiro(heights)
print(f"Shapiro-Wilk W   : {stat:.4f}")
print(f"p-value          : {p:.4f}")
print("정규분포 만족 (p>0.05)" if p > 0.05 else "정규분포 불만족")
```

```
# 경험적 규칙 (68-95-99.7) 검증
r1 = ((heights>=mean-std) & (heights<=mean+std) ).mean()*100
r2 = ((heights>=mean-2*std) & (heights<=mean+2*std)).mean()*100
print(f"평균±1σ 내 비율 : {r1:.1f}% (이론: 68.3%)")
print(f"평균±2σ 내 비율 : {r2:.1f}% (이론: 95.4%)")
print("=" * 45)
```

▶ 실행 결과 (텍스트 출력)

```
=====
평균(Mean)      : 171.4182 cm
중앙값(Median)  : 171.0000 cm
표준편차(Std)   : 4.7985 cm
왜도(Skewness)  : 0.0534
첨도(Kurtosis)  : -0.7015
IQR 하한선      : 157.5 cm
IQR 상한선      : 185.5 cm
이상치 수       : 0개
Shapiro-Wilk W   : 0.9747
p-value         : 0.2973
정규분포 만족 (p>0.05)
평균±1σ 내 비율 : 63.6% (이론: 68.3%)
평균±2σ 내 비율 : 100.0% (이론: 95.4%)
=====
```

▶ 결과 해석: Shapiro-Wilk 검정 $p=0.2973 > 0.05$ 이므로 귀무가설을 기각하지 못합니다. 즉 95% 신뢰수준에서 정규분포를 따른다고 판단합니다. 이상치는 0개이며, $\pm 1\sigma$ 비율 63.6%가 이론값 68.3%보다 낮은 것은 첨도 -0.75의 평탄 분포 특성 때문입니다.

3-2. 시각화 코드 (박스플롯 / 히스토그램+KDE / Q-Q Plot)

```
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm
import numpy as np
from scipy import stats

# 한글 폰트 설정 (환경별로 경로 수정 필요)
font_path = "/path/to/NotoSansCJK-Regular.ttc"
prop = fm.FontProperties(fname=font_path)
plt.rcParams["font.family"] = prop.get_name()
plt.rcParams["axes.unicode_minus"] = False

# 미리 계산된 통계값
mean = heights.mean() # 171.42 cm
std = heights.std() # 4.80 cm

# [그래프 1] Box Plot -----
fig, ax = plt.subplots(figsize=(5, 5))
ax.boxplot(heights, vert=True, patch_artist=True, widths=0.55,
            boxprops=dict(facecolor="#A8C8E8", color="#555"),
            medianprops=dict(color="#C00000", linewidth=2),
            whiskerprops=dict(color="#555", linestyle="--"),
            flierprops=dict(marker="o", color="red", markersize=6))
ax.set_ylabel("Height (cm)", fontproperties=prop)
ax.set_title("키(Height) 분포 - Box Plot", fontproperties=prop)
ax.grid(axis="y", alpha=0.3)
plt.tight_layout()
plt.savefig("boxplot.png", dpi=150)
plt.show()
```

```
# [그래프 2] 히스토그램 + KDE -----
fig, ax = plt.subplots(figsize=(7, 4.5))
ax.hist(heights, bins=10, density=True,
        color="#5B9BD5", alpha=0.75, edgecolor="white")

kde_x = np.linspace(155, 190, 300)
ax.plot(kde_x, stats.gaussian_kde(heights)(kde_x),
        color="#C00000", lw=2.2, label="KDE 곡선")
ax.plot(kde_x, stats.norm.pdf(kde_x, mean, std),
```

```


        color="#375623", lw=1.8, ls="--", label="정규분포 곡선")
ax.axvline(mean, color="#C00000", ls="-",
            label=f"평균 {mean:.2f}")
ax.axvline(heights.median(), color="#FF9900", ls="-.",
            label=f"중앙값 {heights.median():.1f}")
skew = heights.skew(); kurt = heights.kurtosis()
ax.text(0.97, 0.97,
        f"n={len(heights)}\nSkew={skew:.4f}\nKurt={kurt:.4f}",
        transform=ax.transAxes, va="top", ha="right",
        fontsize=9, bbox=dict(boxstyle="round",
                                facecolor="lightyellow", alpha=0.85))
ax.set_title("키(Height) 히스토그램 & KDE", fontproperties=prop)
ax.set_xlabel("Height (cm)", fontproperties=prop)
ax.set_ylabel("밀도 (Density)", fontproperties=prop)
ax.legend(prop=prop); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig("histogram_kde.png", dpi=150)
plt.show()

# [그래프 3] Q-Q Plot -----
fig, ax = plt.subplots(figsize=(5.5, 4.5))
(osm, osr), (slope, intercept, _) = stats.probplot(heights)
ax.scatter(osm, osr, color="#5B9BD5", s=50, alpha=0.85)
x_ln = np.array([min(osm), max(osm)])
ax.plot(x_ln, slope*x_ln+intercept, color="#C00000", lw=2)
sw_stat, sw_p = stats.shapiro(heights)
ax.text(0.04, 0.97,
        f"Shapiro-Wilk\W={sw_stat:.4f}\np={sw_p:.4f}",
        transform=ax.transAxes, va="top", fontsize=9,
        bbox=dict(boxstyle="round",facecolor="lightyellow",alpha=0.85))
ax.set_title("Q-Q Plot (정규성 검정)", fontproperties=prop)
ax.set_xlabel("이론적 분위수", fontproperties=prop)
ax.set_ylabel("표본 분위수 (Height, cm)", fontproperties=prop)
ax.legend(prop=prop); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig("qqplot.png", dpi=150)
plt.show()

```

▶ 실행 결과 그래프


[그래프 1] Box Plot



[그림 3-1] height 박스플롯: $Q1=168$, 중앙값=171, $Q3=175$

▶ 본인 해석: 박스 중앙선이 박스 중간 부근에 위치하고, 수염 바깥으로 점이 없어 이상치 0개를 시각적으로 확인합니다. 위쪽 수염이 조금 더 길어 왜도 0.05의 미약한 양의 왜도와 일치합니다.


[그래프 2] 히스토그램 + KDE 곡선



[그림 3-2] 히스토그램(파란 막대) + KDE 곡선(빨간선) + 정규분포 이론 곡선(초록 점선)

▶ 본인 해석: KDE 곡선이 정규분포 이론 곡선과 유사하며 단봉(Unimodal) 분포임을 확인합니다. 정규분포보다 봉우리가 낮고 평평한 형태가 첨도 -0.75의 평탄 분포(Platykurtic) 특성과 일치합니다. 평균선과 중앙값선이 거의 겹쳐 분포의 대칭성을 재확인합니다.

[그래프 3] Q-Q Plot



[그림 3-3] Q-Q Plot: 포인트가 기준선에 밀착될수록 정규분포에 가까움

▶ 본인 해석: 대부분의 포인트가 빨간 기준선에 잘 밀착되어 정규성을 시각적으로 확인합니다. 양 끝단에서 기준선을 약간 벗어나는 S자 패턴이 미미하게 나타나는데, 이는 첨도 -0.75의 경량 꼬리(Light-tailed) 특성과 정확히 일치합니다. Shapiro-Wilk $p=0.2973$ 이 이 시각적 판단을 통계적으로 뒷받침합니다.

★. 결과 종합 해석

분석 항목	결과값	통계적 결론
정규성 (Shapiro-Wilk)	$W=0.9747$, $p=0.2973$	$p>0.05 \rightarrow$ 정규분포 만족
이상치 (IQR Tukey)	0개 / 범위 157.5~185.5 cm	극단값 없음
왜도 (Skewness)	0.0534 (거의 대칭)	$ \text{skew} <0.5$: 대칭 분포
첨도 (Kurtosis)	-0.7015	정규(=0)보다 납작: Platykurtic
경험적 규칙 $\pm 1\sigma$	63.6% (이론 68.3%)	평탄 분포로 이론값보다 낮음
경험적 규칙 $\pm 2\sigma$	100.0% (이론 95.4%)	이상치 없어 전부 포함됨
95% 신뢰구간 (평균)	170.12 ~ 172.72 cm	모평균 추정 구간

▶ 종합적으로, height.csv 키 데이터($n=55$)는 정규분포에 가까운 대칭 분포를 보입니다. Shapiro-Wilk 검정 ($p=0.2973$)으로 정규성이 통계적으로 확인되었고 이상치도 0개입니다. 다만 첨도 -0.75가 나타내는 평탄 분포 특성으로 인해 경험적 규칙의 $\pm 1\sigma$ 비율이 이론값(68.3%)보다 약 4.7%p 낮게 측정되었으며, 이는 데이터가 평균 근처보다 고르게 분산되어 있음을 의미합니다.

실제 제미니아이와 챗지피티와 클라우드세가지 무료버전에서 실행하였습니다. 가장 드라마틱하게 나온 것이 클루드였고 결과데이터들은 동일하였습니다. 실제로 파이선에서 일일이 하지않아도 생성형ai로 프로프트만 잘 작성하면 훌륭한 결과를 나온다는 사실이 놀라웠습니다.