

2026 매치업 심화과정

통계를 활용한 탐색적 데이터 분석

6주차 과제 제출 보고서

과제명	데이터 프로파일링, 이상치 탐색 및 변수 간 가설 설정 프롬프트 설계
데이터셋	UCI Adult Income Dataset (미국 인구센서스 추출 데이터)
분석 목적	소득(\$50K 초과 여부)에 영향을 미치는 변수 탐색 및 가설 설정
제출 형식	Word 문서 (.docx)

문항	배점
문항 1 – 기술통계 (자료형 확인 + 기술통계 도출)	20점
문항 2 – 이상치 탐색	20점
문항 3 – 대표성 확인 (확률분포 + 정규분포)	30점
문항 4 – 가설설정 (범주-연속 / 범주-범주 / 연속-연속)	30점
합계	100점

문항 1 | 기술통계 결과를 도출하는 프롬프트 작성 [20 점]

데이터를 처음 마주했을 때 전체적인 구조를 파악하기 위한 프롬프트를 다음 두 가지 세부 요구사항에 맞추어 각각 작성합니다.

1-1) 자료형 확인 프롬프트 [10 점]

작성 프롬프트

[역할 부여]

너는 숙련된 데이터 분석가야. 내가 제공하는 Python pandas DataFrame(변수명: adult)을 분석해 줘.

[데이터 맥락]

이 데이터셋은 미국 인구센서스에서 추출한 성인 소득 데이터로, age, workclass, fnlwgt, education, education-num, marital-status, occupation, relationship, race, sex, capital-gain, capital-loss, hours-per-week, native-country, income 총 15개 컬럼으로 구성되어 있어.

[수행 작업]

아래 세 가지를 모두 수행하는 Python 코드를 작성해줘:

- ① adult.info()를 사용해 컬럼명, 비결측치(Non-null) 개수, 데이터 타입을 한눈에 출력해줘.
- ② adult.dtypes를 사용해 각 컬럼의 자료형을 Series 형태로 출력해줘.
- ③ 수치형(int64,float64) 컬럼과 범주형(object) 컬럼을 각각 리스트로 분리하여 출력해줘.

[제약 조건]

오류 발생 시 try-except 예외 처리 포함, 각 출력 앞에 # 주석으로 목적을 설명해줘.

나눔고딕 한글 폰트를 matplotlib 기본값으로 설정해줘.

수업 실습 코드

```

import pandas as pd

# 데이터 불러오기
file_path = "/content/drive/MyDrive/Classroom/EDA심화/data/adult.data"
column_names = [
    "age", "workclass", "fnlwgt", "education", "education-num",
    "marital-status", "occupation", "relationship", "race", "sex",
    "capital-gain", "capital-loss", "hours-per-week", "native-country", "income"
]

# read_csv로 csv 파일 읽기
adult = pd.read_csv(file_path, header=None, names=column_names,
                    na_values="?", skipinitialspace=True)

# 자료형 확인
print(adult.dtypes)

# 요약 통계
print(adult.describe(include='all'))

# 크기 확인
print(adult.shape)

```

🔗 해석 및 분석 의의

자료형 확인은 EDA의 첫 번째 단계로 이후 분석 방법론 선택의 기준이 됩니다.

수치형 변수(age, fnlwgt 등)는 평균·표준편차 등 모수 통계량을 적용할 수 있으며,

범주형 변수(workclass, education 등)는 빈도 분석 및 카이제곱 검정에 활용합니다.

adult 데이터셋은 수치형 6개, 범주형 9개 변수로 구성되어 있으며,

결측치(? 처리)가 일부 범주형 변수에 존재하므로 사전 확인이 필수입니다.

1-2) 기술통계 도출 프롬프트 [10 점]

◆ 작성 프롬프트

[역할 부여]

너는 통계 분석 전문가야. 아래 지시에 따라 adult DataFrame의 기술통계량을 산출하는 Python 코드를 작성해줘.

[수행 작업]

- ① adult.describe()로 수치형 변수 전체의 기술통계 요약 테이블(count, mean, std, min, 25%,

50%, 75%, max)을

소수점 2자리로 반올림하여 출력해줘.

② 수치형 변수(select_dtypes(include='number'))의 평균(mean), 중앙값(median), 표준편차(std), 제1사분위수(Q1=25%), 제3사분위수(Q3=75%), 최솟값(min), 최댓값(max)을 하나의 요약 DataFrame으로 출력해줘.

③ scipy.stats의 skew, kurtosis 함수로 각 수치형 변수의 왜도(Skewness)와 첨도(Kurtosis)를 계산하고

위 DataFrame에 추가해줘.

④ 범주형 변수(workclass 등)는 value_counts()로 빈도수와 비율을 함께 DataFrame으로 출력해 줘.

[출력 형식]

결과는 pandas DataFrame으로 정리하고, 나눔고딕 한글 폰트를 matplotlib 기본값으로 설정해줘. 막대그래프와 파이차트로 범주형 분포도 시각화해줘.

◆ 수업 실습 코드 (범주형)

```
import pandas as pd
import matplotlib.pyplot as plt

# workclass 빈도수와 비율
cnt = adult['workclass'].value_counts(dropna=False)
prop = adult['workclass'].value_counts(normalize=True, dropna=False)

# 빈도와 비율을 함께 보기
summary_df = pd.DataFrame({'Count': cnt, 'Proportion': prop})
print(summary_df)

# 막대그래프
plt.figure(figsize=(10, 5))
cnt.plot(kind='bar', color='skyblue')
plt.title('Workclass Distribution')
plt.ylabel('Count')
plt.xticks(rotation=45)
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()
```

◆ 수업 실습 코드 (연속형)

```

import pandas as pd
from scipy.stats import skew, kurtosis

# 기술통계 요약
summary = adult.describe()

# 연속형 변수 선택
continuous_vars = adult.select_dtypes(include='number')

# 표준편차 계산
std_devs = continuous_vars.std()

# 왜도(skewness) 및 첨도(kurtosis) 계산
skewness_vals = continuous_vars.apply(skew)
kurtosis_vals = continuous_vars.apply(kurtosis)

# 결과 종합 보기
eda_summary = pd.DataFrame({
    'std_dev': std_devs,
    'skewness': skewness_vals,
    'kurtosis': kurtosis_vals
})
print(summary)
print(eda_summary)

```

🔗 해석 및 분석 의의

평균과 중앙값의 차이가 크면 분포가 비대칭임을 의미합니다.

capital-gain의 왜도(11.95)와 첨도(154.77)가 매우 높아 극단값이 존재함을 확인할 수 있습니다.

→ 로그 변환 또는 이진화(0/1) 처리가 필요합니다.

education-num은 왜도 -0.31, 첨도 0.62로 상대적으로 정규분포에 가까워 모델 설명 변수로 적합합니다.

workclass는 Private 부문이 약 70% 이상으로 데이터 불균형이 존재하므로 모델링 시 주의가 필요합니다.

📁 문항 2 | 이상치 탐색 결과 코드를 도출하는 프롬프트 작성 [20 점]

단순히 "이상치 찾아줘"가 아니라 IQR 기준($1.5 \times IQR$)과 Z-score 기준을 명시하여 통계적 근거를 기반으로 탐색 코드를 유도합니다.

◆ 작성 프롬프트

[역할 부여]

너는 데이터 품질 관리 전문가야. adult DataFrame에서 수치형 변수들의 이상치를 통계적 기준으로 탐지하는 Python 코드를 작성해줘.

[이상치 탐지 기준 1 – IQR 방법]

각 수치형 변수에 대해 아래 절차를 따라줘:

- $Q1 = \text{quantile}(0.25)$, $Q3 = \text{quantile}(0.75)$ 계산
- $IQR = Q3 - Q1$ 계산
- 하한: $\text{lower} = Q1 - 1.5 \times IQR$, 상한: $\text{upper} = Q3 + 1.5 \times IQR$
- lower 미만이거나 upper 초과인 값을 이상치로 판별하고 개수와 인덱스를 출력

[이상치 탐지 기준 2 – Z-score 방법]

- $Z\text{-score} = (\text{값} - \text{평균}) / \text{표준편차}$ 계산
- $|Z\text{-score}| > 3$ 인 값을 이상치로 판별하고 개수를 출력

[시각화]

seaborn boxplot으로 수치형 변수 전체의 이상치를 subplot 격자 형태로 시각화해줘.

[결과 정리]

변수명, IQR 기준 이상치 개수, Z-score 기준 이상치 개수를 하나의 DataFrame으로 정리하여 출력해줘.

[제약 조건]

try-except 예외 처리 포함, 나눔고딕 한글 폰트 설정, 각 단계 # 주석 포함.

◆ 수업 실습 코드 (Z-score & IQR)

```
import numpy as np

# 나이 (age) 변수 추출
testdata = adult['age']

# 평균과 표준편차 계산
```

```

mean_score = testdata.mean()
std_score = testdata.std()

# 표준점수(Z-score) 계산
z_scores = (testdata - mean_score) / std_score

# 이상치 인덱스 (Z-score가 ±3을 넘는 경우)
outliers_indices = np.where(np.abs(z_scores) > 3)[0]
print("이상치 개수(Z-score):", len(outliers_indices))

# IQR 방법으로 age 변수 이상치 탐지
Q1 = testdata.quantile(0.25)
Q3 = testdata.quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

outliers_indices = testdata[(testdata < lower_bound) | (testdata >
upper_bound)].index
print("이상치 개수(IQR):", len(outliers_indices))

```

◆ 수업 실습 코드 (박스플롯 시각화)

```

import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# 연속형 변수 목록
numeric_cols = adult.select_dtypes(include='number').columns

# 박스플롯 시각화
n_cols = 2
n_rows = int(np.ceil(len(numeric_cols) / n_cols))
plt.figure(figsize=(n_cols * 6, n_rows * 4))
for i, col in enumerate(numeric_cols):
    plt.subplot(n_rows, n_cols, i + 1)
    sns.boxplot(y=adult[col], color='lightblue')
    plt.title(col)
    plt.grid(True)
plt.tight_layout()
plt.show()

```

🔗 해석 및 분석 의의

IQR 방법은 정규성 가정 없이 사용 가능하며, Z-score 방법은 정규분포를 따를 때 더 정확합니다.

수업 실습 결과, capital-gain은 IQR 기준 2,712개 / Z-score 기준 215개 이상치가 검출되었습니다.

→ 대부분 값이 0에 집중되어 있고 일부 고소득자의 극단적 자본 이득에 기인합니다.
capital-loss, hours-per-week도 이상치가 다수 발견되어 로그 변환 또는 이진화가 권장됩니다.
age는 이상치(고령자)가 존재하지만 전체 분포는 비교적 안정적이므로 그대로 사용 가능합니다.

☑ 문항 3 | 대표성 확인 결과 코드를 도출하는 프롬프트 작성 [30 점]

수집된 샘플 데이터가 모집단을 잘 대표하는지, 어떤 수리적 특성을 가졌는지 확인하기 위한 프롬프트를 작성합니다.

3-1) 확률분포 확인 프롬프트 [15 점]

◆ 작성 프롬프트

[역할 부여]

너는 통계 시각화 전문가야. adult DataFrame의 연속형 변수들의 확률분포를 시각적으로 확인하는 Python 코드를 작성해줘.

[시각화 요구사항]

- ① select_dtypes(include='number')로 수치형 변수를 선택해줘.
- ② 각 변수에 대해 히스토그램(Histogram)과 커널밀도추정(KDE) 곡선을 함께 그려줘.
seaborn의 histplot(kde=True, bins=30)을 사용해줘.
- ③ 전체 변수를 2열 구성의 subplot 격자로 배치하고, 각 subplot 제목에 변수명을 표시해줘.
- ④ 각 히스토그램에 평균선(mean, 빨간 점선)과 중앙값선(median, 파란 점선)을 수직선으로 추가해줘.

[해석 요구]

코드 실행 후 각 변수의 분포 형태를 print로 요약해줘:

정규 분포에 가까운지, 우측 꼬리(양의 왜도)인지, 좌측 꼬리(음의 왜도)인지.

[제약 조건]

나눔고딕 한글 폰트 설정, plt.tight_layout() 적용, try-except 예외 처리 포함.

◆ 수업 실습 코드

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# 연속형 변수 선택
numeric_cols = adult.select_dtypes(include='number').columns

# 히스토그램 + KDE 시각화
n_cols = 2
n_rows = int(np.ceil(len(numeric_cols) / n_cols))

plt.figure(figsize=(n_cols * 6, n_rows * 4))
for i, col in enumerate(numeric_cols):
    plt.subplot(n_rows, n_cols, i + 1)
    sns.histplot(adult[col], kde=True, bins=30, color=(0.8, 0.2, 0.5, 0.5))
    plt.title(col)
    plt.xlabel('')
    plt.ylabel('')

plt.tight_layout()
plt.show()
```

🔗 해석 및 분석 의의

히스토그램과 KDE 곡선을 함께 보면 분포의 전반적인 형태를 육안으로 쉽게 파악할 수 있습니다.

capital-gain, capital-loss: 대부분 0에 집중된 강한 우측 꼬리 분포 → 로그 변환 또는 이진화 권장

hours-per-week: 40시간 중심의 비교적 정규에 가까운 형태 → 고소득자와의 관계 분석에 활용 가능

education-num: 대체로 정규분포 형태 → 모델 설명력 높은 변수 후보

KDE 곡선은 히스토그램 구간 설정에 의존하지 않는 비모수적 밀도 추정으로 실제 분포를 더 부드럽게 표현합니다.

3-2) 정규분포 확인 프롬프트 [15 점]

◆ 작성 프롬프트

[역할 부여]

너는 통계 검정 전문가야. adult DataFrame의 연속형 변수들이 정규분포를 따르는지 엄밀하게 검증하는 Python 코드를 작성해줘.

[정규성 검정 방법 1 – Anderson-Darling 검정]

- `scipy.stats.anderson`을 사용해줘 (대용량 데이터에 적합).
- 귀무가설(H_0): 데이터는 정규분포를 따른다.
- 대립가설(H_1): 데이터는 정규분포를 따르지 않는다.
- 검정통계량이 임계값(유의수준 5% 기준)을 초과하면 H_0 기각으로 판단.

[정규성 검정 방법 2 – Shapiro-Wilk 검정]

- `scipy.stats.shapiro`를 사용해줘 (표본 크기 5,000 이하에 적합).
- $p\text{-value} < 0.05$ 이면 H_0 기각 → 정규분포 아님.

[정규성 시각화 – Q-Q Plot]

`scipy.stats.probplot`과 `matplotlib`으로 각 수치형 변수의 Q-Q Plot을 그려줘.

점들이 대각선에 가까울수록 정규분포에 가까움을 설명하는 주석도 포함해줘.

[결과 정리]

변수명, 검정통계량, p-value, 정규분포 여부 판단 컬럼을 포함한 결과 DataFrame을 출력해줘.

[제약 조건]

try-except 포함, 한글 폰트 설정, 각 단계 # 주석 포함.

◆ 수업 실습 코드

```
from scipy.stats import anderson

# 데이터: education-num 변수
edu_data = adult['education-num'].dropna() # 결측값 제거

# Anderson-Darling 정규성 검정
ad_result = anderson(edu_data, dist='norm')

# 출력
print("Test Statistic:", ad_result.statistic)
print("Critical Values:", ad_result.critical_values)
print("Significance Levels:", ad_result.significance_level)

# 결과 해석
for stat, sl in zip(ad_result.critical_values, ad_result.significance_level):
    if ad_result.statistic > stat:
```

```
print(f"At {sl}% significance level: 정규분포를 따르지 않음 (귀무가설 기각)")
else:
    print(f"At {sl}% significance level: 정규분포를 따름 (귀무가설 유지)")
```

🔗 해석 및 분석 의의

수업 실습에서 education-num의 Anderson-Darling 검정 p-value < 0.00000000000000022로 귀무가설이 기각되었습니다.

→ 시각적으로 정규에 가까워 보여도 표본이 크면(n=32,561) 미세한 비정규성도 통계적으로 유의하게 검출됩니다.

정규성을 따르지 않는 변수에 대한 처리 방법:

- 데이터 변환: 로그 변환(log()), 제곱근 변환(sqrt()), Box-Cox 변환, Yeo-Johnson 변환
- 비모수 방법 사용: t-검정 대신 Mann-Whitney U, ANOVA 대신 Kruskal-Wallis, 피어슨 상관계수 대신 스피어만 순위 상관계수 또는 켄달의 타우

📄 문항 4 | 가설설정 코드를 도출하는 프롬프트 작성 [30 점]

변수의 속성(유형) 조합에 따라 서로 다른 통계 분석 기법을 적용합니다. 각 조합에 맞는 가설 설정 및 검정 코드를 도출하는 프롬프트를 각각 작성합니다.

4-1) 범주형 - 연속형 변수 간 관계 [10 점]

적용 기법: 독립표본 t-검정(two-sample t-test) / ANOVA

예시: income(범주형, 이진) ↔ age / education-num / hours-per-week(연속형)

H₀ (귀무가설): income 그룹(<=50K / >50K)에 따라 age의 모집단 평균은 동일하다.

H₁ (대립가설): income 그룹에 따라 age의 모집단 평균은 유의미하게 다르다.

◆ 작성 프롬프트

[역할 부여]

너는 가설 검정 전문가야. adult DataFrame에서 범주형 변수와 연속형 변수 간의 관계를 통계적으로 검정하는 Python 코드를 작성해줘.

[가설 설정]

- H0: income 그룹(<=50K / >50K)에 따라 age의 모집단 평균은 동일하다.
- H1: income 그룹에 따라 age의 모집단 평균은 유의미하게 다르다.

[검정 방법]

- ① 정규성 검정 후 정규분포를 따르면 `scipy.stats.ttest_ind`로 독립표본 t-검정을 수행해줘.
- ② 정규성을 따르지 않으면 `scipy.stats.mannwhitneyu`(비모수 대안)를 사용해줘.
- ③ 3개 이상 그룹 비교 시 `scipy.stats.f_oneway`(ANOVA)를 적용해줘.
- ④ p-value < 0.05이면 "H0 기각(두 그룹 간 유의한 차이 존재)"을 출력해줘.

[시각화]

seaborn boxplot으로 income 그룹별 age 분포를 시각화하고, 각 박스 위에 그룹 평균값을 표시해 줘.

[확장]

age 외에도 education-num, hours-per-week에 대해 동일한 검정을 반복 수행하고 결과를 DataFrame으로 정리해줘.

[제약 조건]

try-except 예외 처리, 한글 폰트 설정, 각 단계 # 주석 포함.

◆ 수업 실습 코드

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# 연속형 변수 목록
numeric_cols = adult.select_dtypes(include='number').columns

# 박스플롯: income 그룹별로 연속형 변수 분포 시각화
n_cols = 2
n_rows = int(np.ceil(len(numeric_cols) / n_cols))
```

```
plt.figure(figsize=(n_cols * 6, n_rows * 4))
for i, col in enumerate(numeric_cols):
    plt.subplot(n_rows, n_cols, i + 1)
    sns.boxplot(x='income', y=col, data=adult, palette='pastel')
    plt.title(f'{col} Distribution by Income')
    plt.xlabel('Income')
    plt.ylabel(col)

plt.tight_layout()
plt.show()
```

🔗 해석 및 분석 의의

수업 실습에서 income 그룹별 boxplot 비교 결과:

- age: >50K 그룹이 <=50K보다 중앙값이 높음 → 고소득층은 중·장년층 이상이 많음
- education-num: >50K 그룹이 교육연수 평균이 유의하게 높음 → 유의한 설명 변수
- hours-per-week: >50K 그룹이 더 긴 근무시간 → 업무 투입 시간과 소득 연관성 강함

두 박스의 중앙값과 IQR 범위가 상이하게 나타나면 두 변수는 상관이 있다고 판단합니다.

→ age, education-num, hours-per-week을 예측 모델의 주요 설명 변수로 채택 가능합니다.

4-2) 범주형 – 범주형 변수 간 관계 [10 점]

적용 기법: 카이제곱 독립성 검정(Chi-Square Test of Independence)

예시: income(이진 범주형) ↔ sex / workclass / education(범주형)

H₀ (귀무가설): sex(성별)와 income(소득 수준)은 서로 독립이다 (연관성이 없다).

H₁ (대립가설): sex와 income은 서로 독립이지 않다 (통계적으로 유의미한 연관성이 있다).

◆ 작성 프롬프트

[역할 부여]

너는 범주형 데이터 분석 전문가야. adult DataFrame에서 범주형 변수들이 income과 통계적으로 독립인지 검정하는 Python 코드를 작성해줘.

[가설 설정]

- H₀: sex(성별)와 income(소득 수준)은 서로 독립이다 (연관성이 없다).

- H1: sex와 income은 서로 독립이지 않다 (유의미한 연관성이 있다).

[검정 방법 - 카이제곱 독립성 검정]

- ① pd.crosstab으로 sex와 income의 교차표(분할표)를 생성해줘.
- ② scipy.stats.chi2_contingency로 카이제곱 통계량(chi2), 자유도(dof), p-value, 기대빈도(expected)를 계산해줘.
- ③ p-value < 0.05이면 "H0 기각 → 통계적으로 유의한 관계"를 출력해줘.

[반복 검정]

select_dtypes(include='object')로 모든 범주형 변수를 선택해 income과의 카이제곱 검정을 반복 수행하고,

변수명·카이제곱 통계량·p-value·독립 여부를 DataFrame으로 정리하여 출력해줘.

[제약 조건]

try-except 포함, 한글 폰트 설정, 각 단계 # 주석 포함.

◆ 수업 실습 코드

```
import pandas as pd
from scipy.stats import chi2_contingency

# 1. 범주형 변수 선택
categorical_vars = adult.select_dtypes(include='object').columns.tolist()

# 2. 'income' 제외
categorical_vars = [var for var in categorical_vars if var != 'income']

# 3. 결과를 저장할 리스트 생성
results_list = []

# 4. 변수별로 카이제곱 독립성 검정
for var in categorical_vars:
    contingency_table = pd.crosstab(adult[var], adult['income'])
    chi2, p, dof, expected = chi2_contingency(contingency_table)
    results_list.append({
        'variable': var,
        'p_value': p,
        'is_independent': p > 0.05  # p > 0.05이면 독립으로 판단
    })
```

```
# 5. 리스트를 DataFrame으로 변환 및 출력
result_adult = pd.DataFrame(results_list)
print(result_adult)
```

🔗 해석 및 분석 의의

수업 실습 결과, 모든 범주형 변수(workclass, education, marital-status, occupation, relationship, race, sex, native-country)에서 `is_independent = FALSE`로 나타났습니다.

→ 모든 범주형 변수가 income과 통계적으로 유의미한 연관성이 있습니다(독립적이지 않음).

카이제곱 검정은 연관성의 존재 여부를 알려주지만 방향성은 알려주지 않으므로, 크래머의 V(Cramer's V)를 함께 계산해 연관성 강도를 파악하는 것이 좋습니다.

유의미한 범주형 변수는 원-핫 인코딩 후 머신러닝 모델에 투입할 수 있습니다.

4-3) 연속형 - 연속형 변수 간 관계 [10 점]

적용 기법: 피어슨 / 스피어만 상관분석(Correlation Analysis)

예시: age ↔ education-num, hours-per-week ↔ capital-gain

H₀ (귀무가설): age와 education-num 사이에 선형 상관관계가 존재하지 않는다 ($p = 0$).

H₁ (대립가설): age와 education-num 사이에 유의미한 상관관계가 존재한다 ($p \neq 0$).

◆ 작성 프롬프트

[역할 부여]

너는 상관관계 분석 전문가야. adult DataFrame에서 연속형 변수들 간의 선형 및 단조 연관성을 통계적으로 검정하는 Python 코드를 작성해줘.

[가설 설정]

- H₀: age와 education-num 사이에 선형 상관관계가 존재하지 않는다 ($p = 0$).
- H₁: age와 education-num 사이에 유의미한 상관관계가 존재한다 ($p \neq 0$).

[검정 방법 1 - 피어슨 상관분석 (정규분포 가정)]

- scipy.stats.pearsonr로 상관계수(r)와 p-value를 계산해줘.
- 해석 기준: $|r| \geq 0.7$ 강한 상관, 0.4~0.7 중간 상관, 0.4 미만 약한 상관.
- p-value < 0.05이면 "H0 기각 → 유의미한 상관관계 존재"를 출력해줘.

[검정 방법 2 – 스피어만 순위 상관분석 (비모수)]

- scipy.stats.spearmanr로 스피어만 상관계수와 p-value를 계산해줘.
- 정규성 검정 결과에 따라 피어슨과 스피어만 중 적합한 방법을 자동 선택하도록 분기해줘.

[상관행렬 시각화]

- DataFrame.corr()로 수치형 변수 전체의 피어슨 상관계수 행렬을 계산해줘.
- seaborn heatmap(annot=True, fmt='.2f', cmap='coolwarm')으로 시각화해줘.

[제약 조건]

try-except 포함, 한글 폰트 설정, 각 단계 # 주석 포함.

◆ 수업 실습 코드

```
import pandas as pd

# 연속형 변수만 골라내기
numeric_df = adult.select_dtypes(include='number')

# 피어슨 상관계수 행렬 계산
cor_matrix = numeric_df.corr()

# 결과 출력
print(cor_matrix)

# heatmap 시각화 (선택)
# import seaborn as sns
# sns.heatmap(cor_matrix, annot=True, fmt='.2f', cmap='coolwarm')
# plt.tight_layout()
# plt.show()
```

🔗 해석 및 분석 의의

수업 실습 결과, 수치형 변수 간 상관계수가 대부분 0.15 이하로 낮게 나타났습니다.

→ 연속형 변수 간에는 강한 선형 상관관계가 거의 없습니다.

이는 다중공선성 문제 없이 여러 변수를 회귀 모델에 동시에 투입할 수 있음을 의미합니다.

상관계수 해석 기준:

- $|r| \geq 0.7$: 강한 상관관계
- $0.4 \leq |r| < 0.7$: 중간 정도 상관관계
- $|r| < 0.4$: 약한 상관관계

education-num과 hours-per-week의 상호작용이 소득에 영향을 줄 수 있으므로

파생 변수(interaction term) 생성도 검토할 필요가 있습니다.

📖 종합 정리

문항	분석 목적	적용 통계 기법	핵심 발견
문항 1	데이터 구조·수치 특성 파악	dtypes, describe(), skew, kurtosis	20점
문항 2	극단치·오류값 탐지	IQR(1.5배) + Z-score(± 3)	20점
문항 3	모집단 대표성·정규성 검증	Histogram+KDE, Anderson-Darling	30점
문항 4	변수 간 관계 및 가설 검정	t-test / 카이제곱 / 상관분석	30점

본 과제를 통해 생성형 AI를 활용한 EDA의 전 과정을 체계적으로 수행하는 프롬프트를 설계하였습니다. 핵심은 단순히 "코드를 짜줘"가 아니라 통계적 근거(IQR, Z-score, p-value 기준 등)와 출력 형식, 제약 조건(예외 처리, 폰트 설정)을 명시하여 AI가 실무 수준의 코드를 생성하도록 유도하는 것입니다.