

중고차 데이터를 활용한 가격 예측 모델 보고서

탐색적 데이터 분석(EDA) 기반 분석 보고서

통계를 활용한 탐색적 데이터 분석

고려사이버대학교 미래교육원 | 매치업 심화과정

제출일: 2026. 09. 15.

제출자: 유현주

데이터셋: Audi Used Car Dataset (UK)

1. 데이터 탐색 및 기술통계

본 보고서는 영국 중고차 플랫폼에서 수집된 Audi 차량 데이터셋을 분석하여, 차량 특성과 가격 간의 관계를 탐색하고 예측 모델 수립을 위한 근거를 마련하고자 합니다.

1.1 데이터 기본 구조

항목	내용
총 행(관측치) 수	10,668개
총 열(변수) 수	9개
결측치	없음 (완전 데이터)
수치형(연속형) 변수 (6개)	year, price, mileage, tax, mpg, engineSize
범주형 변수 (3개)	model, transmission, fuelType

데이터셋은 10,668개의 중고 Audi 차량 데이터로 구성되며, 결측치 없이 완전히 정제된 상태입니다. 변수는 수치형 6개와 범주형 3개로 구성되어 있어 회귀 모델 수립에 적합한 구조를 갖추고 있습니다.


1.2 주요 변수 기술통계

변수	평균	중앙값	최솟값	최댓값	표준편차
price (£)	22,897	20,200	1,490	145,000	11,715
year	2017.1	2017	1997	2020	2.17
mileage (mi)	24,827	19,000	1	323,000	23,505
tax (£)	126.0	145	0	580	67.2
mpg	50.8	49.6	18.9	188.3	12.95
engineSize (L)	1.93	2.0	0.0	6.3	0.60

1.3 범주형 변수 분포

변수	고유값 수	주요 범주
model (차종)	26개	A3(1,929) > Q3(1,417) > A1(1,347) > A4(1,381) 등
transmission (변속기)	3개	Manual(4,369) > Semi-Auto(3,591) > Automatic(2,708)
fuelType (연료유형)	3개	Diesel(5,577) > Petrol(5,063) > Hybrid(28)

1.4 가격 분포 시각화



[그림 1] 가격 분포 히스토그램 및 상자그림

가격(price) 분포를 확인한 결과, 왜도(Skewness)가 2.28로 강한 우편향 분포를 나타냅니다. 평균 (£22,897)이 중앙값(£20,200)보다 높은 것은 고가 차종(R8, Q8 등)의 영향입니다. IQR 방식 기준으로 443개의 이상치가 확인되며, 이는 고급-스포츠 차종에 해당합니다. 로그 변환 시 왜도가 -0.11로 정규분포에 근접하므로, 모델 수립 시 로그 변환을 검토할 필요가 있습니다.

1.5 왜도(Skewness) 및 첨도(Kurtosis)

변수	왜도	첨도	분포 특성
price	2.28	11.67	강한 우편향, 고첨도 → 로그변환 필요
year	-1.45	5.18	좌편향 (최근 연도 집중)
mileage	1.58	4.58	우편향 (저주행 차량 많음)
mpg	1.83	14.05	우편향, 최고 첨도
tax	0.60	6.05	약한 우편향
engineSize	1.21	3.72	약한 우편향

2. 가설검정을 위한 탐색적 데이터 분석

2.1 가설 설정


본 분석에서는 범주형 변수가 중고차 가격에 유의미한 영향을 미치는지 검정합니다.

구분	내용
가설 1	차종(model)에 따라 평균 가격 차이가 있다
가설 2	변속기 유형(transmission)에 따라 평균 가격 차이가 있다
검정 방법	가설 1: 일원 분산분석(One-way ANOVA), 가설 2: 독립표본 t-검정 (Automatic vs Manual)
유의수준(α)	0.05

2.2 가설 1: 차종별 평균 가격 차이 (ANOVA)

귀무가설(H_0): 모든 차종의 평균 가격은 동일하다

대립가설(H_1): 적어도 하나의 차종은 평균 가격이 다르다



[그림 2] 차종별 가격 분포 (상위 12개 차종 박스플롯)


검정 통계량	자유도	p-값	결론
F = 490.09	df1=25, df2=10642	p < 0.001	귀무가설 기각 ✓

F-통계량이 490.09로 매우 크고 p-값이 0.001보다 훨씬 작아, 유의수준 0.05에서 귀무가설을 기각합니다. 즉, 차종에 따라 평균 가격이 통계적으로 유의미하게 다릅니다. R8(평균 £97,652), Q8(£60,115), RS6(£55,964) 등 프리미엄 모델과 A1(£14,328), A2(£2,490) 등 보급형 모델 간 현저한 가격 차이가 존재합니다.

2.3 가설 2: 변속기 유형별 평균 가격 차이 (t-검정)

귀무가설(H_0): Automatic 변속기와 Manual 변속기의 평균 가격은 동일하다

대립가설(H_1): 두 변속기 유형의 평균 가격은 다르다



[그림 3] 변속기 유형별 및 연료유형별 평균 가격 비교


그룹	표본 수	평균 가격 (£)	중앙값 (£)
Automatic	2,708	28,205	26,500
Manual	4,369	16,101	15,700
Semi-Auto	3,591	27,162	24,250

검정 통계량	p-값	결론
t = 53.50	p < 0.001	귀무가설 기각 ✓


Automatic 변속기 차량의 평균 가격(£28,205)이 Manual 차량(£16,101)보다 약 £12,104 높으며, t-통계량 53.50, p-값이 0.001보다 훨씬 작아 통계적으로 유의미한 차이가 확인됩니다. 또한 연료 유형 ANOVA 검정 결과($F=10.99$, $p<0.001$), Hybrid 차량(평균 £30,192)이 Diesel(£23,238) 및 Petrol(£22,481)보다 유의미하게 높은 가격을 보입니다.

3. 모델 수립을 위한 탐색적 데이터 분석 (EDA)

3.1 연속형 변수와 가격 간 산점도 분석



[그림 4] 가격 vs 주행거리 및 가격 vs 연식 산점도




[그림 5] 가격 vs 연비(MPG) 산점도

산점도 분석 결과 다음과 같은 관계가 확인됩니다:

- price ↑ vs mileage ↓: 주행거리가 낮을수록 가격이 높은 경향 ($r = -0.535$)
- price ↑ vs year ↑: 최근 연식일수록 가격이 높은 경향 ($r = +0.593$)
- price ↑ vs mpg ↓: 연비가 낮을수록 가격이 높음 ($r = -0.600$, 고배기량 고가차 영향)

3.2 상관관계 히트맵 분석



[그림 6] 수치형 변수 간 상관관계 히트맵

변수	price와의 상관계수	방향	해석
mpg	-0.600	부(-)의 상관	가장 강한 음의 상관 (연비 ↓ → 가격 ↑)
year	+0.593	정(+)의 상관	최신 연식일수록 가격 높음
engineSize	+0.591	정(+)의 상관	배기량 클수록 가격 높음
mileage	-0.535	부(-)의 상관	주행거리 길수록 가격 낮음
tax	+0.356	정(+)의 상관	세금 높을수록 가격 높은 경향

주요 예측 변수로 year, engineSize, mileage, mpg가 선별됩니다. 단, mpg와 engineSize 간 상관관계(-0.65)가 강하므로, 다중공선성 방지를 위해 두 변수 중 하나를 선택하거나 VIF 분석을 통한 변수 선별이 필요합니다.

3.3 범주형 변수별 평균 가격 비교 요약

범주형 변수	고유값 수	가격 차이	모델 반영 방식
model (차종)	26	£2,490 ~ £97,652 (39배 차이)	원핫 인코딩 또는 그룹 축소
transmission (변속기)	3	£16,101 ~ £28,205 (1.75배 차이)	원핫 인코딩

범주형 변수	고유값 수	가격 차이	모델 반영 방식
fuelType (연료유형)	3	£22,481 ~ £30,192 (1.34배 차이)	원핫 인코딩

4. 간단한 결론

4.1 주요 분석 결과 요약

구분	핵심 내용
데이터 품질	10,668개 관측치, 9개 변수, 결측치 없음
가격 분포	평균 £22,897, 중앙값 £20,200, 우편향 분포 (왜도 2.28) → 로그변환 권장
이상치	443개 (세금 변수에 가장 많은 이상치 3,287개)
가설 1 결론	ANOVA $F=490.09$, $p<0.001$ → 차종별 평균 가격 차이 유의미 (귀무가설 기각)
가설 2 결론	$t=53.50$, $p<0.001$ → 변속기 유형별 가격 차이 유의미 (귀무가설 기각)
핵심 예측 변수	$\text{year}(r=+0.59)$, $\text{engineSize}(r=+0.59)$, $\text{mileage}(r=-0.54)$, $\text{mpg}(r=-0.60)$

4.2 모델 수립 제언

- 주요 예측 변수: year, mileage, engineSize를 우선 투입하고, mpg는 다중공선성 검토 후 선택
- 범주형 변수(model, transmission, fuelType)는 원핫 인코딩 처리 후 모델 투입
- 가격 변수는 로그 변환 후 선형 회귀 적용 권장 (왜도 감소: 2.28 → -0.11)
- 모델 성능 평가: 결정계수(R^2), RMSE, MAE 지표 활용
- 대안 모델: Random Forest, Gradient Boosting 등 트리 기반 앙상블 모델 검토 가능

4.3 종합 해석

본 EDA 분석을 통해 Audi 중고차 가격은 ① 차종(모델), ② 변속기 유형, ③ 최신 연식, ④ 낮은 주행거리, ⑤ 큰 배기량 순으로 강하게 영향을 받음을 확인하였습니다. 특히 차종 변수는 F-통계량 490.09로 가장 강력한 가격 결정 요인으로 분석됩니다. 향후 다중선형회귀 또는 랜덤 포레스트 모델 수립 시 본 EDA 결과를 기반으로 변수를 구성할 것을 권장합니다.

본 보고서는 고려사이버대학교 미래교육원 매치업 심화과정「통계를 활용한 탐색적 데이터 분석」8주차 기말 프로젝트 제출물입니다.